

文章编号: 1003-0077 (2017) 00-0000-00

基于图卷积记忆网络的方面级情感分类

王光¹, 李鸿宇^{1,2}, 邱云飞¹, 郁博文², 柳厅文²

(1. 辽宁工程技术大学 软件学院, 辽宁 葫芦岛 125105;

2. 中国科学院 信息工程研究所, 北京 100089)

摘要: 在方面级情感分类中, 常用的方法是将循环神经网络或卷积神经网络和注意力机制结合, 利用注意力获取序列中不同单词的重要程度。但此类方法未能很好地利用文本的句法信息, 导致模型不能准确对评价词与方面词之间建立联系。该文提出一种图卷积神经网络模型(MemGCN)解决此依赖问题。通过记忆网络存储文本表示与辅助信息, 并利用基于依存句法树的图卷积神经网络获取文本的句法信息。最后, 使用注意力机制融合句法与其他辅助信息。在 SemEval 2014 任务和 Twitter 数据集上的实验结果表明, MemGCN 显著地提升了模型性能。

关键词: 句法信息; 图卷积神经网络; 注意力机制; 辅助信息

中图分类号: TP391

文献标识码: A

Aspect-based Sentiment Classification Based on Memory Graph Convolutional Network

WANG Guang¹, LI Hongyu^{1,2}, QIU Yunfei¹, YU Bowen², LIU Tingwen²

(1. School of Software, Liaoning Technical University, Huludao, Liaoning 125105, China;

2. Institute of Information Engineering, Chinese Academy of Sciences, Beijing 100089, China)

Abstract : In aspect-based sentiment classification, the attention mechanism is often combined in recurrent neural network or convolutional neural network to obtain the importance of different words. However, such kind of methods fail to capture long-range syntactic relations that are obscure from the surface form, which would be beneficial to identify sentiment features directly related to the aspect target. In this paper, we propose a novel model named MemGCN to explicitly utilize the dependency relationship among words. Firstly, we employ the memory network to obtain the context-aware memory representation. After that, we apply graph convolutional network over the dependency tree to propagate sentiment features directly from the syntactic context of an aspect target. Finally, attention mechanism is used to fuse memory and syntactic information. We conduct extensive experiments on the SemEval 2014 and Twitter dataset, and results demonstrate that our model outperforms baseline methods.

Key words: syntactic information; graph convolutional network; attention mechanism; auxiliary information

0 引言

方面级情感分类是一种细粒度情感分析任务, 目标是确定评论文本中所出现不同方面的情感倾向^[1-2]。例如给出“**Great food** but the service was **dreadful**!”的评论内容和“food”、“service”两个方面, 需要模型判断出评论者对方面词

“food”的情感倾向是积极的, 而对方面词“service”是负向的。文中使用下划线标识的词汇是方面词, 通过粗体表示评价词。如图 1 的方面级情感分类示例图所示, 同一个句子中评论者对不同方面词的情感倾向是不同的, 评价词与方面词的对应关系决定每个方面词的情感。方面级情感分类相比于传统的篇章级别, 和句子级别的

收稿日期: 20**_**_**; 定稿日期: 20**_**_**

基金项目: 国家自然科学基金 (71371091)

情感分类任务来说更有针对性,一方面为用户决策提供更细粒度的参考,另一方面为商家指明产品改进方向。




图1 方面级情感分类示例

近年来,基于深度学习的各类模型在方面级情感分类任务中取得了很好的效果,然而现有方法没有很好地利用句法信息来辅助分类。一般来说,方面级情感分类任务中的评价词往往出现在句法关系复杂的文本中,以句子“**We didn’t know if we should order a drink or leave?**”为例,方面词“drink”的情感倾向是十分复杂的,需要全局的语义理解和推断,而句法关系能够帮助模型找到“drink”相关的评价词,进而完成情感分类。受到文献[4]图卷积神经网络(GCN, Graph Convolutional Network)在文本分类领域成功应用的启发,本文提出了一种结合图神经网络和注意力机制的方面级情感分类方法 MemGCN,它能够有效利用句法依存信息辅助分类。在三个公开的方面级情感分类数据集上,我们证明了 MemGCN 模型的优越性能。

1 相关工作

传统的方面级情感分类的相关研究主要基于特征工程和统计模型。Kiritchenko 等^[5]使用领域内情感词典和外部语料提取特征,将支持向量机(SVM, Support Vector Machine)作为分类器,在 SemEval-2014 任务四,方面级情感分析评测任务中达到当时的最好效果。

但是使用情感词典、构建特征的方式不仅需要大量的人工参与,而且统计机器学习的分类器

已经达到性能瓶颈,很难对方面与句子中上下文建模。随着深度学习的兴起,基于循环神经网络(RNN, Recurrent Neural Network)和卷积神经网络(CNN, Convolutional Neural Network)的方法在方面级情感分类任务中则会取得良好的效果。Tang 等^[7]提出依赖和连接目标的 TD-LSTM 模型,利用双向的长短期记忆网络(LSTM, Long Short Term Memory Network)建模方面词,使模型兼顾方面和情感信息。

目前,注意力机制在自然语言处理领域,如机器翻译、问答系统、自动文摘等任务中均得到了广泛应用^[8-9],Wang 等^[10]结合 LSTM 和注意力机制提出了带有方面词嵌入的 AB AE-LSTM 模型,证明了注意力机制不仅可以注意到句子中如评价词等重要信息,而且还能注意到方面词,这对方面级情感分类提供了重要帮助。曾锋等^[11]使用双层注意力对单词和句子同时建模,在长文本评论的方面级情感分类中获得了性能的提升。

Xue 等^[12]针对结合注意力机制和 LSTM 过于复杂,不能并行训练的问题,结合卷积神经网络和门控机制提出了 GCAE 模型;梁斌等^[13]将方面的词性、位置等信息输入到卷积神经网络模型中,提出一种多注意力卷积神经网络;刘全等^[14]将区域卷积神经网络和分层循环神经网络应用到了方面情感分类任务中;杜慧等^[15]将词向量、词性信息和注意力同时融入 CNN 和 LSTM 中,提高了模型的训练速度和性能。此外,Tang 等^[16]通过调节记忆网络的注意力机制层数在 SemEval-2014 任务四中获得当时最好效果;Chen 等^[18]提出基于循环注意力机制的记忆网络模型;Zhu 等^[22]设计了两个基于注意力机制的记忆网络分别建模情感词和方面词,进一步提升了情感分类效果。

2 基于图卷积记忆网络的方面级情感分类

MemGCN 模型框架主要包括文本表示层、语义学习层、位置记忆层、图卷积神经网络层、注意力层和情感分类层六部分,整体框架如图 1 所示。为便于理解和描述,本文将文中的相关符号表示进行以下说明,句子形式化表示为 $S=\{w_1, w_2, \dots, w_{t-1}, w_t, \dots, w_{t+l}, w_{t+l+1}, \dots, w_n\}$, 其中 n 表示句子中词的数目,方面词为 w_t, \dots, w_{t+l} , 可能由一个或多个词构成。 t 和 l 分别表示词的位置和方面词的长度, w_1, w_2, \dots, w_{t-1} 与 w_{t+l+1}, \dots, w_n 分别指代上文词和下文词。

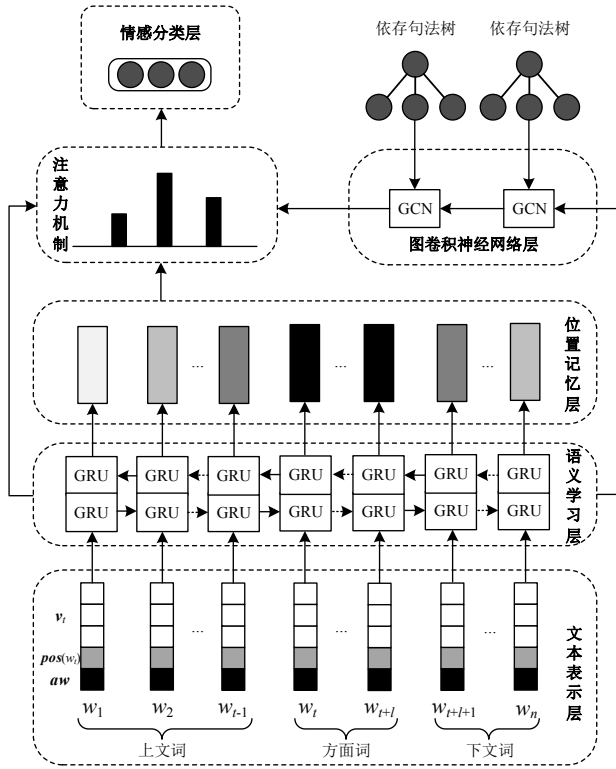


图2 图卷积记忆网络结构图

2.1 文本表示层

Word2Vec、FastText、GloVe等^[8]无监督词表示方法广泛应用于自然语言处理的各项任务中,不但能够表示文本的语义信息,而且可以捕获词的语法信息。假设词向量词典为 $T \in \mathbf{R}^{d \times |V|}$, 其中 d 与 $|V|$ 分别表示词向量维度和词典中词的个数,则将句子 S 映射为稠密表示后的符号表达是

$V=\{v_1, v_2, \dots, v_{t-1}, v_t, \dots, v_{t+l}, v_{t+l+1}, \dots, v_n\}$ 。受到先前工作的启发,本文将单词的词性和目标方面词也嵌入为稠密表示,并与词向量进行拼接作为文本表示层的输出,数学符号表示为 $x_t=\{[v_1; pos(w_1); aw], [v_2; pos(w_2); aw], \dots, [v_{t-1}; pos(w_{t-1}); aw], [v_t; pos(w_t); aw], \dots, [v_{t+l}; pos(w_{t+l}); aw], [v_{t+l+1}; pos(w_{t+l+1}); aw], \dots, [v_n; pos(w_n); aw]\}$, 其中 pos 表示词性向量的映射, aw 为当前句子所关注的方面词向量,对于同一个句子中出现多个方面词的情况,则采取数据预处理的方式分成多条数据进行判断。

2.2 语义学习层

文本评论数据中词之间存在时间序列关系,循环神经网络能够学习到长距离的语义依赖信息。门控循环单元(GRU, Gate Recurrent Unit)是一种循环神经网络,基本结构如图 2 所示,采用门控机制避免一般循环神经网络梯度弥散的问题,而且比 LSTM 拥有更少的参数量,训练的速度更快。




图3 门控循环单元结构图

图 2 中的 x_t 和 h_{t-1} (初始化为 x_t) 为 GRU 的输入信息,分别表示 t 时刻经过词语表示层转化的数据和上一时刻 GRU 输出的状态信息。 z_t 和 r_t 分别表示更新门和重置门,如计算公式(1)和(2)所示。 \tilde{h}_t 是要被添加到记忆单元的候选值,见公式(3)。 h_t 表示 GRU 的 t 时刻输出,计算公式为(4)。

$$z_t = \sigma(W_z[h_{t-1}, x_t] + b_z) \quad (1)$$

$$r_t = \sigma(W_r[h_{t-1}, x_t] + b_r) \quad (2)$$

其中 σ 表示 sigmoid 激活函数, W_z 和 W_r 分别表示更新门和重置门的权重, b_z 和 b_r 分别表示更新门和重置门的偏置。更新门用于控制前一时刻的状态信息被带入到当前状态中的程度, 更新门的值越大说明前一时刻的状态信息带入越多。重置门控制前一状态有多少信息被写入到当前的候选集 \tilde{h}_t 上, 重置门越小表示前一状态的信息被写入的越少。

$$\tilde{h}_t = \tanh(W_h[r_t \times h_{t-1}, x_t] + b_h) \quad (3)$$

公式(3)中 \tanh 是双曲正切激活函数, W_h 与 b_h 分别为记忆单元候选集的权重和偏置。记忆单元候选集通过重置门得到的信息判断记忆信息是否重置。最后, 综合更新门和记忆单元候选集学习到的信息计算 t 时刻 GRU 的输出。

$$h_t = z_t \times \tilde{h}_t + (1 - z_t) \times h_{t-1} \quad (4)$$

Tom 等^[8]通过实验证明正反双向的循环网络会同时学习到上下文语义信息, 因此本文借助双向门控循环单元(BGRU, Bidirectional Gate Recurrent Unit)完成语义学习, 最终学习得到的语义信息 h_t^r 如公式(7)所示。

$$\tilde{h}_t = \text{GRU}(x_t, \tilde{h}_{t-1}) \quad (5)$$

$$\tilde{h}_t = \text{GRU}(x_t, \tilde{h}_{t-1}) \quad (6)$$

$$h_t^r = \tilde{h}_t + \tilde{h}_t \quad (7)$$

2.3 位置记忆层

在方面级情感分类任务中, 方面词与上下文的相对位置蕴含着重要的信息。距离方面词越近的词越有可能是该方面的评价词, 应该具有更高的权重。本文使用位置记忆网络保存词语的位置权重, 如公式(8)所示。

$$w_t^{pm} = 1 - \frac{|p_t - p_a| - 1}{L} \quad (8)$$

w_t^{pm} 表示位置记忆权重范围在 0 到 1 之间, 公式(8)中 p_t 和 p_a 分别为文本评论中上下文和方面词在句子中的位置, 若方面词为多个词则仅保留一个位置, L 指的是句子的长度, 分子中减一的目的是防止位置权重为零, 以区分方面词。位置记忆网络层的输出计算结果 h_t^{pm} 见公式(9), 其中 w_t^{pm} 由公式(8)计算得到, h_t^r 是语义学习层的输出结果。

$$h_t^{pm} = w_t^{pm} h_t^r \quad (9)$$

2.4 图卷积神经网络层

句法分析是自然语言处理领域的一个研究方向。在方面级情感分类任务中, 不同方面的多个评价词往往存在于复杂的句法结构中, 句法信息变得尤为重要。由于本文主要解决方面级情感分类问题, 因此依存句法分析任务主要借助 SpaCy 工具获得依存句法分析树。文本评论“**Great food but the service was dreadful!**”的依存句法树结构示例见图 4。




图 4 依存句法树示例图

基于依存句法分析树的图卷积神经网络获取句法信息的示例结构如图 5 所示。




图 5 图卷积神经网络结构图

为了让模型能够感知到句法结构信息, 本文引入了图卷积神经网络^[3]。GCN 能够处理由句法依存树得到的对称邻接矩阵 A 所表示的图。首先对邻接矩阵 A 进行归一化处理, D 表示句法依存树的度矩阵, 如公式(10)所示。

$$\tilde{A} = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \quad (10)$$

$$h_t^g = \tilde{A} \text{ReLU} \left(\tilde{A} h_t^r W_g^{(0)} \right) W_g^{(1)} \quad (11)$$

由文献[3]可知 GCN 层数为 2 时训练出模型的效果最好, 因此本文使用双层 GCN 获取文本的句法信息。公式(11)中, ReLU 表示线性整流激活函数, $W_g^{(0)}$ 和 $W_g^{(1)}$ 分别表示图卷积神经网络第一层和第二层的权重, h_t^r 是语义学习层学习到的隐藏状态, h_t^g 表示图卷积神经网络层的输出结果。

2.5 注意力机制

为了充分利用记忆网络存储的语义、词性、方面与位置信息和图卷积神经网络模块得到的句法信息, 本文提出了一种考虑到句法等辅助信息的注意力机制。

$$v_t = h_t^{pm} h_t^g \quad (12)$$

$$a_t = \frac{\exp(v_t)}{\sum_{t=1}^n \exp(v_t)} \quad (13)$$

$$h_a = \sum_{t=1}^n a_t h_t^r \quad (14)$$

公式(12~14)中, h_t^r 、 h_t^{pm} 和 h_t^g 分别为语义学习层、位置记忆层和图卷积神经网络层的输出, \exp 表示以 e 为底的指数函数, h_a 为注意力机制的输出。

2.6 情感分类层

本文所采用的方面级情感分类公开数据集均包括正向、中性和负向三种情感, 属于多分类问题, 分类器将方面位置注意层输出信 h_a 作为输入,

计算情感类别的概率, 见公式(15)。

$$P_s = \text{softmax}(W_s h_a + b_s) \quad (15)$$

其中 W_s 和 b_s 分别为情感分类层的权重和偏置, P_s 是情感分类层的输出, 表示模型预测文本评论数据属于正向、中性和负向三种情感类别的概率。

3 实验

3.1 数据集

为验证本文提出模型的优越性, 本文在三个公开数据集上进行实验, 分别为 SemEval-2014 任务四^[5]的餐馆和笔记本电脑领域的方面级用户评论数据集, 以及由 Dong 等^[6]基于 Twitter 所整理的社交领域的方面级评论数据。每个数据集均包括用户评论文本数据、单独列出的方面词和方面的情感类别标签, 并且情感类别都为正向、中性和负向情感三种类别, 数据集的标签类别分布统计表见表 1。

表 1 数据集标签类别分布统计表

数据集	正向的	中性的	负向的
Laptop-Train	994	464	870
Laptop-Test	341	169	128
Restaurant-Train	2164	637	807
Restaurant-Test	728	196	196
Twitter-Train	1561	3127	1560
Twitter-Test	173	346	173

3.2 评价指标

本文采用准确率 *Accuracy* 和 *Macro-F1* 值, 文中简称为 F1 值, 作为评价指标, 验证方面级情感分类任务中模型性能。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (16)$$

$$Macro - F1 = \frac{2 \times P \times R}{P + R} \quad (17)$$

公式(17)中, P 为由计算公式(18)得出的

Macro-Precision, R 代表 Macro-Recall, 由公式(19)计算得到。

$$\text{Macro-Precision} = \frac{1}{C} \sum_{i=1}^C \frac{TP_i}{TP_i + FN_i} \quad (18)$$

$$\text{Macro-Recall} = \frac{1}{C} \sum_{i=1}^C \frac{TP_i}{TP_i + FP_i} \quad (19)$$

公式(18)和(19)中的 C 代表分类标签的类别数, 本文包括正向、中性和负向三类情感标签, 因此本文中 C 为 3。TP(True Positive)、TN(True Negative)分别表示预测正确的正向、中性和负向情感类别的样本数, FP(False Positive)、FN(False Negative)则分别表示预测错误的正向、中性和负向情感类别的样本数。

3.3 目标函数

本文提出的模型可以通过反向传播的方式完成端到端的训练, 方面级情感分类问题是多分类任务, 因此目标函数使用交叉熵损失函数。使用 y 表示数据实际的情感类别, \hat{y} 代表模型预测的情感类别, 具体见公式(20)。

$$\text{loss} = \sum_{i=1}^D \sum_{j=1}^C y_i^j \log \hat{y}_i^j + \lambda \|\theta\|^2 \quad (20)$$

公式(20)中的 D 表示训练数据的数目, C 与公式(18)和(19)的意义相同, 代表情感类别个数, 本文中 C 为 3。为防止训练时过拟合, 本文在交叉熵损失函数上增加二范数正则化项, λ 为正则化项系数。

3.4 参数设置

本文采用基于梯度下降算法的 Adam 优化器训练模型, 学习率设置为 10^{-3} , 模型连续 5 次性能为下降则提前终止训练。使用两种词嵌入方法, 一种是 GloVe840B^[20]预训练的 300 维词向量, 模型的输入是上文词+方面词+下文词, 另一种预训练语言模型 BERT_Base Uncased^[21]包含 12 层网

络结构, 词向量维度是 768 维, 模型的输入为 “[CLS]” + 上文词+方面词+下文词+ “[SEP]” + 方面词+ “[SEP]”, 两种文本表示方式构建模型的输出均为所输入方面词的情感类别。未登录词与 50 维的词性向量使用满足均匀分布的 $(-0.01, 0.01)$ 矩阵进行随机初始化。为避免模型训练过拟合, 随机失活 Dropout 参数设置为 0.5, 正则化项系数 λ 设置为 10^{-5} 。

3.5 对比模型

本文对比模型如下:

- **SVM^[5-6]**: 利用情感词典和 n 元语法等特征, 使用支持向量机作为分类器处理特征, 完成分类。

- **LSTM**: 采用标准的长短期记忆网络完成方面级情感分类。

- **TD-LSTM^[7]**: 依赖目标的长短期记忆网络(Target-Dependent LSTM)。考虑方面词信息, 拼接前向和后向 LSTM 的隐藏层向量用于细粒度情感分类。

- **ATAE-LSTM^[10]**: 结合方面词信息和注意力机制的长短期记忆网络(Attention-Based LSTM with Aspect Embedding)。引入方面词嵌入, 结合注意力机制关注句子中给定方面的部分。

- **GCAE^[12]**: 基于门控机制的卷积神经网络(Gated Convolutional Networks)。结合卷积神经网络和门控机制进行方面级情感分类, 卷积核数目设置为 100, 卷积核的尺寸分别是 3、4 和 5。

- **IAN^[17]**: 交互注意力网络(Interactive Attention Network)。建立方面词与上下文的双向注意力机制进行方面级情感分类。

- **RAM^[18]**: 基于记忆块的循环注意力网络(Recurrent Attention Network on Memory)使用循环注意力机制完成分类任务, 多跳数目设置为 3。

• AOA^[19]: 同时关注方面词和上下文句子的注意力机制网络 (Attention-over-Attention Network)。联合学习方面词和句子的表示, 并且基于注意力机制自动关注句子中重要部分。

3.6 实验结果与分析

实验在型号为 Tesla P100 的 GPU 服务器上进行, 使用 Intel(R)Xeon(R)CPU E5-2620 处理器, 32GB 内存, 操作系统选用 Ubuntu 16.04.6 LTS, 开发平台是 Python 3.6.2, 基于 PyTorch 深度学习框架构建模型。在三个领域测试集上模型的指标

对比结果如表 2 所示, 评价指标分别是 3.2 节所介绍的准确率 *Accuracy* 和宏平均的 F1 值, 最好的结果使用加粗表示。由于 SVM 论文作者使用人工特征和相关词典与规则而无法进行复现, 因此引用 Kiritchenko 等^[5]与 Dong 等^[6]论文中结果进行实验对比, NA 表示相关论文中未给出的评测数值。表中其余对比模型均为本文复现的结果, 除了 MemGCN-BERT 模型外, 均采用 GloVe 词向量进行文本表示, 并且取五次实验的平均值作为最终结果。

表 2 测试集上模型的评测结果表

模型	Laptop		Restaurant		Twitter	
	准确率	F1 值	准确率	F1 值	准确率	F1 值
SVM	70.49	NA	80.16	NA	63.40	63.30
LSTM	69.59	62.73	77.32	65.29	68.87	66.76
TD-LSTM	70.47	64.79	78.73	68.75	69.85	67.85
ATAE-LSTM	73.07	67.97	79.44	68.86	70.28	68.51
GCAE	70.43	64.75	79.16	68.75	70.11	67.83
IAN	71.47	65.78	78.80	68.14	70.52	68.93
RAM	74.16	69.95	80.23	70.35	70.08	68.47
AOA	73.19	68.57	80.07	69.75	71.18	68.84
MemGCN	74.38	70.30	81.55	72.87	72.19	70.29
MemGCN-BERT	78.68	73.93	85.18	77.32	72.98	72.08

实验结果如表 2 所示, 基于情感词典和人工特征的 SVM 情感分类器已经达到很好的分类效果, 在餐馆领域数据集上超过了普通的 LSTM, 但是它们都未考虑到方面级情感分类对方面词的依赖。TD-LSTM 借助前向和后向 LSTM 对方面词建立依赖关系, 在三个数据集上性能均得到了 2% 的提升。ATAE-LSTM 的准确率和 F1 值比 LSTM 提升 1%~3%, 证明了利用方面词做词嵌入和融入注意力机制的有效性。基于卷积神经网络的 GCAE, 在三个数据集上均达到与 TD-LSTM 相近的性能, 但是卷积神经网络具有能够并行计算, 而且训练速度更快的优势。

IAN、RAM 与 AOA 均为注意力机制与循环神经网络的不同结合方式, 从表 2 的结果可以看

出, IAN 在笔记本电脑和餐馆领域性能略低于 RAM, 而在推文数据集上效果更好, AOA 在三个公开数据集上均取得较好的效果, 这说明合理地设计注意力机制的结构能够改善模型对方面级情感分类的效果。

本文提出的注意文本词性信息、方面信息与位置信息和句法信息的 MemGCN 模型在餐馆、电脑领域和社交领域均取得优异的方面级情感分类效果。MemGCN 模型的准确率相比 LSTM 提高了 4% 左右, F1 值在三个数据集上的效果提升均超过 6%。同时, 本文还使用了预训练语言模型作为文本表示层, 训练出来的 MemGCN-BERT 模型在三个领域数据集上均取得了最好的结果, 这证明了预训练语言模型 BERT 对语言的表示能

力优于 GloVe, 因此在下游的图卷积记忆网络能够更好地完成方面级情感分类。虽然预训练的语言模型可以达到最佳分类效果, 但是需要消耗大量的时间和资源训练模型, 得到的模型也会占用较多存储空间。而且在表 2 中也可以发现, 在训练数据量较多的推文社交数据集上, 基于两种文本表示方法所训练出来的模型性能是比较接近的。




图6 句法与辅助信息对分类准确率影响

为了验证文本评论的词性信息、方面信息与位置信息和句法信息对模型分类准确率和 F1 值的影响, 本文还对 MemGCN 模型进行了如图 6 和图 7 所示的对比实验。图中黑柱是同时包括所

有辅助信息的完整 MemGCN 模型, 灰黑色、灰色、灰白色和白色柱分别为去掉位置信息、句法信息、词性信息与方面词信息的实验结果。




图7 句法与辅助信息对分类 F1 值影响

首先由图 6 和图 7 中均可以看出, 位置信息、句法信息、词性信息与方面信息都会辅助 MemGCN 模型进行分类。其次, 本文提出的句法信息对于三个数据集的影响是最大的, 这是由于方面词大多处于具有复杂句法结构的句子中, 句法信息能够在情感分类时帮助模型找到与方面词相关的文本评价词部分。总的来说, 辅助信息对 MemGCN 模型性能影响的重要程度依次为, 方面信息、位置信息和词性信息。

表3 实例分析

实例	方面词	GCAE	IAN	RAM	AOA	MemGCN	类别
Great <u>food</u> but the <u>service</u> was dreadful !	<u>food</u>	负向	负向	正向	正向	正向	正向
	<u>service</u>	负向	正向	正向	负向	负向	负向
We didn't know if we should order a <u>drink</u> or leave ?	<u>drink</u>	负向	负向	负向	负向	中性	中性

为了探索不同模型之间的性能差异, 本文分别对基于卷积神经网络的 GCAE, 基于循环神经网络与注意力机制的 IAN、RAM 和 AOA, 与本文提出的 MemGCN 模型进行实例分析。如表 3 所示, 最后一列的类别表示真实数据标签。可以看出, MemGCN 模型能够根据不同方面词进行正

确的情感分类, 而其他模型很难对句法结构相对复杂的中性情感表达进行正确判断。

图 8~10 分别为 MemGCN 在餐馆领域正向、负向和中性情感实例的可视化分析, 在图 8 和图 10 注意力权重示意图中, 颜色越深则代表注意力权重越大。



图 8 “food”、“service”方面注意力权重示意图

如图 8 所示，对于评论文本“**Great** food but the service was **dreadful**!”中的方面词“food”来说，本文提出的 MemGCN 模型对评价词“**Great**”的注意力权重最大，并且评价词“**Great**”是一个带有明显积极情感的形容词，在判断情感类别时能够将“food”方面分类为正向。而当方面词为“service”时，MemGCN 模型的注意力则聚焦于评价词“**dreadful**”，从而判断出评论者对“service”方面的情感为负向。




图 9 实例的依存句法树可视化示意图

通过分析依存句法树可视化示意图 9，可以发现一句话中出现多个方面词与评价词时，图卷积网络所感知的句法信息可以分别建立评价词与对应方面词之间的联系，有效地防止记忆网络在遇到评价词“**dreadful**”时，忘记“**Great**”对“food”方面的评价所产生错误，也可以缓解注意力机制过于强调“**Great**”评价词导致模型在“service”方面的分类错误问题。



图 10 “drink”方面注意力权重示意图

在图 10 中，“We didn’t know if we **should** order a drink or **leave**?”中“drink”的情感倾向为中性，由于训练数据中属于中性情感的数据量

较小，评论中的句法结构较为复杂，具有贬义色彩的词语“**leave**”距离方面词“drink”又很近，因此很容易将这条数据预测为负向情感，而 MemGCN 融入了句法信息，注意力机制同时关注到了“**should**”词和否定词“**n’t**”，将这条数据正确判断为中性情感。

4 总结

为解决复杂句法结构中的方面级情感分类方面词与评价词之间的依赖问题，本文使用注意力机制，结合记忆文本语义、词性、方面与位置信息的记忆网络，和基于依存句法分析树的图卷积神经网络，提出了一种句法信息感知的方面级情感分类模型。实验结果证明了通过加入句法信息，可以增强评价词与方面词之间的联系，能够明显改善方面级情感分类的效果。在未来的工作中，我们将尝试更先进的预训练语言模型优化语义信息，并计划将本文提出的模型在其他细粒度情感分析任务，如评价对象提取中进行尝试。

参考文献

- [1] Liu B. Sentiment analysis and opinion mining[J]. Synthesis Lectures on Human Language Technologies, 2012, 5(1): 1–167.
- [2] Zhou J, Huang J X, Chen Q, et al. Deep Learning for Aspect-Level Sentiment Classification: Survey, Vision, and Challenges. IEEE Access[J], 2019, vol. 7:78454–78483.
- [3] Thomas N, Max W. Semi-supervised classification with graph convolutional networks[C] // Proceedings of the 2017 Conference on International Conference on Learning Representations.
- [4] Liang Y, Mao C S, Luo Y. Graph Convolutional Networks for Text Classification[C] // Proceedings of the AAAI Conference on Artificial Intelligence 33 (2019): 7370–7377.
- [5] Kiritchenko S, Zhu X, Cherry C, et al. NRC-Canada-2014: Detecting aspects and sentiment in customer reviews[C] // Proceedings of the 8th International Workshop on Semantic Evaluation, 2014: 437–442.
- [6] Dong L, Wei F R, Tan C Q, et al. Adaptive Recursive Neural Network for Target-Dependent Twitter Sentiment Classification[C] // Proceedings of the 52nd Annual

- Meeting of the Association for Computational Linguistics. Stroudsburg, USA: ACL, 2014, II: 49-54.
- [7] Tang D Y, Qin B, Feng X C, et al. Effective LSTMs for Target-Dependent Sentiment Classification[C] // Proceedings of the 26th International Conference on Computational Linguistics. Berlin, Germany: Springer, 2016: 3298-3307.
- [8] Tom Y, Devamanyu H, Soujanya P, et al. Recent Trends in Deep Learning Based Natural Language Processing [Review Article]. IEEE Computational Intelligence Magazine[J] 13.3(2018):55-75.
- [9] Bahdanau D, Cho K, Bengio Y. Neural Machine Translation by Jointly Learning to Align and Translate[C/OL]. [2019-05-25]. <https://arxiv.org/pdf/1409.0473.pdf>.
- [10] Wang Y Q, Huang M L, Zhao L, et al. Attention-Based LSTM for Aspect-Level Sentiment Classification[C] // Proceedings of the Conference on Empirical Methods in Natural Language Processing. Stroudsburg, USA: ACL, 2016: 606-615.
- [11] 曾锋, 曾碧卿, 韩旭丽, 等. 基于双层注意力循环神经网络的方面级情感分析[J]. 中文信息学报, 2019, 33(6): 108-115.
- [12] Xue W, Li T. Aspect Based Sentiment Analysis with Gated Convolutional Networks[C] // Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Melbourne, Australia: ACL, 2018: 2514-2523.
- [13] 梁斌, 刘全, 徐进, 等. 基于多注意力卷积神经网络的特定目标情感分析[J]. 计算机研究与发展, 2017, 54(8): 1724-1735.
- [14] 刘全, 梁斌, 徐进, 等. 一种用于基于方面情感分析的深度分层网络模型[J]. 计算机学报, 2018, 41(12): 2637-2652.
- [15] 杜慧, 俞晓明, 刘悦, 等. 融合词性和注意力的卷积神经网络对象级情感分类方法[J]. 模式识别与人工智能, 2018, 31(12): 1120-1126.
- [16] Tang D Y, Qin B, Liu T. Aspect Level Sentiment Classification with Deep Memory Network[C] // Proceedings of the Conference on Empirical Methods in Natural Language Processing. Stroudsburg, USA: ACL, 2016: 214-224.
- [17] Ma D H, Li S J, Zhang X D, et al. Interactive Attention Networks for Aspect-Level Sentiment Classification[C] // Proceedings of the 26th International Joint Conference on Artificial Intelligence. Berlin, Germany: Springer, 2017: 4068-4074.
- [18] Chen P, Sun Z Q, Bing L D, et al. Recurrent Attention Network on Memory for Aspect Sentiment Analysis[C] // Proceedings of the Conference on Empirical Methods in Natural Language Processing. Stroudsburg, USA: ACL, 2017: 452-461.
- [19] Huang B X, Ou Y L, Kathleen M. Aspect Level Sentiment Classification with Attention-over-Attention Neural Networks[C] // Lecture Notes in Computer Science (2018): 197-206.
- [20] Pennington J, Socher R, Manning C D. Glove: Global Vectors for Word Representation[C] // Proceedings of the Conference on Empirical Methods in Natural Language Processing. Stroudsburg, USA: ACL, 2014: 1532-1543.
- [21] Devlin J, Chang M, Lee, K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C] // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: NAACL-HLT 2019, Minneapolis, MN, USA, 2-7 June 2019; Volume 1 (Long and Short Papers), pp. 4171-4186.
- [22] Zhu P S, Qian T Y. Enhanced Aspect Level Sentiment Classification with Auxiliary Memory[C] // Proceedings of the 27th International Conference on Computational Linguistics. Stroudsburg, USA: ACL, 2018: 1077-1087.
- [23] Liu Q, Zhang H B, Zeng Y F, et al. Content Attention Model for Aspect Based Sentiment Analysis[C] // Proceedings of the World Wide Web Conference. Washington, USA: IEEE, 2018: 1023-1032.
- [24] 廖祥文, 林威, 吴运兵, 等. 基于辅助记忆循环神经网络的视角级情感分析[J]. 模式识别与人工智能, 2019, 32(11): 987-996.
- [25] He R D, Lee W S, Ng H T, et al. Exploiting Document Knowledge for Aspect-Level Sentiment Classification[C] // Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, USA: ACL, 2018: 579-585.
- [26] He R D, Lee W S, Ng H T, et al. Effective Attention Modeling for Aspect-Level Sentiment Classification[C] // Proceedings of the 27th International Conference on Computational Linguistics. Stroudsburg, USA: ACL, 2018: 1121-1131.
- [27] Diego M, Ivan T. Encoding sentences with graph convolutional networks for semantic role labeling[C] // Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, pages 1506-1515.
- [28] Majumder N, Poria S, Gelbukh A F, et al. IARM: Inter-Aspect Relation Modeling with Memory Networks in Aspect-Based Sentiment Analysis[C] // Proceedings of the Conference on Empirical Methods in Natural Language Processing. Stroudsburg, USA: ACL, 2018: 3402-3411.
- [29] Xu Y, Yang J. Look again at the syntax: Relational graph convolutional network for gendered ambiguous pronoun resolution[C]. arXiv preprint arXiv:1905.08868, 2019.
- [30] 贾川, 方睿, 浦东, 等. 基于循环实体网络的细粒度情感分析[J]. 中文信息学报, 2019, 33(9): 123-128.



王光 (1979—), 硕士, 副教授, 研究生导师, 主要研究领域为自然语言处理, 情感分析。
E-mail: 275469783@qq.com



李鸿宇 (1994—), 通信作者, 硕士研究生, 主要研究领域为自然语言处理, 情感分析。
E-mail: 1757732597@qq.com



邱云飞 (1976—), 博士, 教授, 博士生导师, 主要研究领域为数据挖掘, 自然语言处理。
E-mail: 7415575@qq.com